
DermaDiff: Deteksi Kanker Kulit secara Interpretatif melalui Optimisasi Vision Foundation Model dengan Augmentasi Sintetis Berbasis Stable Diffusion

Muhammad Ilyas Rusdi
Department of Informatics
Institut Teknologi Sepuluh Nopember
Jawa Timur, Indonesia
5025241007@student.its.ac.id

Afarrel Febryan Ghiffari P.A.
Department of Informatics
Institut Teknologi Sepuluh Nopember
Jawa Timur, Indonesia
5025241137@student.its.ac.id

Jason Kumarkono
Department of Informatics
Institut Teknologi Sepuluh Nopember
Jawa Timur, Indonesia
5025241105@student.its.ac.id

Abstract

Deteksi dini kanker kulit secara signifikan dapat meningkatkan tingkat kelangsungan hidup pasien, namun sistem klasifikasi berbasis AI yang ada saat ini menghadapi dua hambatan fundamental: ketidakseimbangan kelas yang parah pada dataset pelatihan dan sifat black-box model deep learning yang membatasi kepercayaan klinis. Kami menyajikan DermaDiff, sebuah sistem clinical decision support end-to-end yang mengatasi kedua tantangan tersebut melalui tiga komponen terintegrasi: (1) augmentasi sintetis tertarget menggunakan latent diffusion model yang di-fine-tune dengan adapter parameter-efficient (LoRA/DoRA) untuk menghasilkan citra dermoskopik kelas-spesifik pada kategori lesi yang kurang terwakili, (2) PanDerm ViT-Large sebagai classifier vision foundation model khusus dermatologi yang dilatih pada augmented dataset, dan (3) MedGemma 4B IT sebagai komponen interpretatif yang menghasilkan penjelasan klinis berbahasa alami dari output klasifikasi dan attention heatmap. Studi komparatif lima arah pada tiga arsitektur difusi (SD 2.1, SDXL, SD 3.5 Large) dan dua metode adaptasi menunjukkan bahwa SDXL dengan DoRA mencapai performa keseluruhan terbaik (Macro F1: 0,847; Weighted F1: 0,897). Sistem ini dirancang sebagai alat second opinion bagi dokter dengan akses dermoskop, menyediakan penilaian yang transparan dan interpretatif dengan menerapkan prinsip keselamatan escalate-never-clear.

1 Pendahuluan

1.1 Latar Belakang dan Motivasi Klinis

Diagnosis lesi kulit secara akurat dan tepat waktu merupakan tantangan klinis yang signifikan. Kemiripan visual yang tinggi antara lesi jinak dan ganas menyebabkan akurasi inspeksi visual tanpa dermoskopi hanya berkisar 60% [1], sementara keterbatasan jumlah spesialis memperburuk akses terhadap layanan diagnosis. Kanker kulit merupakan salah satu kanker paling umum di dunia, dengan sekitar 2–3 juta kasus non-melanoma dan lebih dari 132.000 kasus melanoma setiap tahun [2]. Melanoma, meskipun hanya mencakup kurang dari 2% kasus, bertanggung jawab atas

lebih dari 80% kematian terkait kanker kulit [3], dengan tingkat kelangsungan hidup lima tahun mencapai 99% jika terdeteksi pada stadium lokal namun menurun drastis pada stadium lanjut [4]. Data tersebut menunjukkan bahwa deteksi dini melanoma merupakan faktor penting dalam meningkatkan peluang kelangsungan hidup pasien.

Deep learning telah menunjukkan kemampuan klasifikasi setara dermatologis ahli [5], namun dua hambatan menghalangi penerapan klinisnya. Pertama, ketidakseimbangan kelas pada dataset pelatihan: HAM10000 [6] memiliki rasio ketidakseimbangan mencapai 58:1, menyebabkan model bias terhadap kelas mayoritas dan mengorbankan deteksi pada kelas yang paling berbahaya [7]. Kedua, model deep learning bersifat black-box sehingga sulit dipercaya oleh tenaga medis sebagai dasar pengambilan keputusan klinis. Untuk menjawab kedua hambatan tersebut, penelitian ini mengusulkan DermaDiff, sebuah produk clinical decision support berbasis AI yang dirancang sebagai second opinion cepat dan interpretatif bagi dokter yang memiliki akses terhadap dermoskop. DermaDiff memanfaatkan ketersediaan PanDerm [8] (Nature Medicine, 2025) dan MedGemma [9] (2025) sebagai komponen fondasi yang sebelumnya tidak ada untuk membangun sistem seperti ini secara end-to-end.

1.2 Positioning dan Value Proposition

DermaDiff merupakan framework deteksi kanker kulit secara interpretatif yang dirancang sebagai clinical decision support. Sistem ini tidak menggantikan diagnosis oleh dokter, melainkan menyediakan second opinion cepat yang selalu tersedia disertai penjelasan dalam bahasa yang mudah dipahami, sehingga dokter tetap menjadi pengambil keputusan yang bertanggung jawab. Empat value proposition utama DermaDiff:

1. **Jangkauan:** dokter yang memiliki akses dermoskop memperoleh penilaian terstruktur atas citra dermoskopi tanpa harus menguasai interpretasi pola dermoskopi secara manual. Ini dapat membantu percepatan penanganan dalam bentuk rujukan ke spesialis.
2. **Kecepatan:** dokter memperoleh second opinion interpretatif dalam hitungan detik saat pemeriksaan, sebagai bahan pertimbangan tanpa menunggu konsultasi sejawat.
3. **Keamanan:** prinsip escalate-never-clear, yaitu sistem selalu menyoroti fitur yang perlu diperhatikan tanpa pernah menyatakan lesi bersifat aman, sehingga kesalahan terburuk adalah kewaspadaan berlebih, bukan kanker yang terlewat.
4. **Kepercayaan:** setiap hasil disertai penjelasan berbahasa alami dari MedGemma sehingga dokter dapat menilai berdasarkan penjelasan bukan secara *blackbox*.

1.3 Pengguna dan Batasan

Pengguna utama DermaDiff adalah dokter yang memiliki akses terhadap dermoskop, baik di klinik maupun rumah sakit. Sistem ini berfungsi sebagai pembaca kedua yang memberi masukan interpretatif atas citra dermoskopi, sementara keputusan klinis tetap sepenuhnya berada pada dokter. Pasien merupakan penerima manfaat (rujukan lebih dini dan lebih tepat), bukan operator sistem. Beberapa batasan yang perlu dicatat:

1. Sistem menerima masukan berupa citra dermoskopi saja; citra dari kamera smartphone tanpa dermoskop belum didukung pada versi saat ini karena evaluasi cross-domain menunjukkan degradasi performa yang belum memadai untuk triase yang aman.
2. Klasifikasi terbatas pada tujuh kategori lesi kulit sesuai taksonomi HAM10000, yaitu melanoma, basal cell carcinoma (BCC), actinic keratoses (AKIEC), dermatofibroma (DF), vascular lesions (VASC), benign keratosis-like lesions (BKL), dan melanocytic nevi (NV).
3. Produk dirancang sebagai alat bantu keputusan (decision support), bukan pengganti diagnosis oleh tenaga medis profesional.

2 Studi Literatur

2.1 Augmentasi Data Tradisional untuk Klasifikasi Lesi Kulit

Teknik augmentasi tradisional, seperti geometric dan photometric transformations, telah menjadi pendekatan umum pada klasifikasi lesi kulit. Perez et al. menunjukkan bahwa augmentasi citra dapat meningkatkan performa klasifikasi lesi kulit dengan memperkaya variasi data pelatihan [10]. Namun, karena hanya memodifikasi citra yang telah ada tanpa menghasilkan variasi morfologi baru, pendekatan ini kurang efektif untuk kelas dengan jumlah sampel yang sangat terbatas, seperti dermatofibroma [11].

2.2 Augmentasi Berbasis Generative Adversarial Networks (GANs)

GAN telah banyak dimanfaatkan untuk augmentasi citra medis dan terbukti mampu meningkatkan performa klasifikasi pada berbagai studi, termasuk pada citra dermoskopi [12], [14]. Namun, keterbatasan seperti training instability dan mode collapse sering menghambat proses pelatihan serta membatasi keragaman citra sintetis yang dihasilkan [13].

2.3 Latent Diffusion Models dan Parameter-Efficient Fine-Tuning

Latent diffusion models menawarkan pendekatan generatif yang lebih stabil dibandingkan GAN dan mampu menghasilkan citra sintetis berkualitas tinggi melalui proses denoising di ruang laten [15]. Adaptasi model ke domain spesifik dapat dilakukan secara efisien menggunakan metode parameter-efficient fine-tuning seperti LoRA dan DoRA [16], [21]. Beberapa penelitian telah mengeksplorasi diffusion-based augmentation untuk dermatologi dan menunjukkan potensinya dalam meningkatkan kualitas data pelatihan [18]–[20].

2.4 Vision Foundation Model untuk Dermatologi

PanDerm ViT-Large (Yan et al., 2025) merupakan vision foundation model multimodal pertama yang dirancang khusus untuk dermatologi klinis [8]. Berbasis ViT-Large dengan 24 blok transformer, PanDerm telah di-pretrain pada dataset dermatologi skala besar dan mengkodekan prior diagnostik seperti pigment networks dan vascular structures. Model ini mencapai performa state-of-the-art, melampaui model ImageNet-pretrained. Namun, PanDerm tetap bergantung pada distribusi data pelatihan, ketika dilatih pada dataset dengan class imbalance parah, recall pada kelas minoritas tetap terdegradasi.

2.5 Explainable AI (XAI) untuk Dermatologi

Explainable AI (XAI) meningkatkan transparansi sistem klasifikasi lesi kulit melalui visualisasi area citra yang memengaruhi keputusan model menggunakan metode seperti Grad-CAM, LIME, dan saliency map [17]–[19]. Studi pada klasifikasi melanoma menunjukkan bahwa visual explanation dapat memiliki kesesuaian dengan karakteristik klinis yang digunakan dermatolog, meskipun tingkat kesesuaiannya bergantung pada metode yang digunakan [19]. Perkembangan medical vision-language model seperti MedGemma membuka peluang untuk menyajikan informasi visual dan tekstual secara terpadu [9].

2.6 Research Gap


Penelitian terdahulu telah mengeksplorasi augmentasi tradisional, GAN, diffusion model, vision foundation model, dan XAI untuk klasifikasi lesi kulit. Kombinasi berpasangan di antaranya juga mulai berkembang, misalnya foundation model berbasis vision-language dengan interpretabilitas berbasis konsep, maupun diffusion model dengan kondisi teks klinis. Namun, foundation model dermatologi dengan performa terbaik saat ini justru bersifat vision-only, sehingga keluarannya berupa representasi visual dan prediksi kelas tanpa penjelasan berbahasa alami. Integrasi ketiga komponen dalam satu alur end-to-end masih jarang ditemukan, yaitu augmentasi sintetis berbasis diffusion untuk mengatasi ketimpangan kelas, optimisasi vision foundation model, dan lapisan penjelasan berbahasa alami yang siap dibaca dokter. Celah inilah yang diisi DermaDiff.

3 Metodologi

3.1 Konsep Produk

DermaDiff terdiri atas tiga komponen utama: (1) Stable Diffusion yang di-fine-tune per kelas minoritas untuk menghasilkan citra dermoskopi sintetis, (2) PanDerm ViT-Large sebagai classifier yang dilatih pada augmented dataset, dan (3) MedGemma 4B IT sebagai komponen interpretatif yang menghasilkan penjelasan tekstual atas keputusan model. Pipeline DermaDiff terdiri atas training pipeline dan inference pipeline.


3.2 Rancangan Pipeline AI/ML




Gambar 1: End-to-end Pipeline

3.2.1 Training dan Inference Data Augmentasi

Pada tahap pelatihan, dataset dipisahkan untuk memperbanyak lima kelas minoritas melalui pembuatan citra sintetis menggunakan Stable Diffusion (LoRA/DoRA), yang kemudian digabungkan dengan data asli untuk melakukan fine-tuning pada PanDerm ViT-Large hingga diperoleh bobot model terbaik. Selanjutnya pada tahap inferensi, citra dermoskopi diproses oleh PanDerm ViT-Large untuk menghasilkan prediksi kelas, distribusi probabilitas, dan attention heatmap, yang kemudian diteruskan sebagai konteks multimodal ke MedGemma 4B IT guna menghasilkan penjelasan klinis berbahasa alami. Seluruh sistem ini dikawal oleh prinsip escalate-never-clear melalui prompt engineering yang secara konsisten memastikan model selalu menyoroti fitur morfologi mencurigakan dan tidak pernah menyatakan suatu lesi bersifat definitif jinak.





3.3 Pemanfaatan Data

DermaDiff memanfaatkan tiga dataset dermoskopi (HAM10000 [6], ISIC 2019 [20], dan Longitudinal Skin Lesion Dataset) untuk fine-tuning Stable Diffusion pada lima kelas minoritas guna memperkaya variasi morfologi lesi, sebagaimana ditunjukkan pada Tabel 1.

Table 1: Dataset untuk Fine-Tuning Stable Diffusion 5 Kelas Minoritas

Sumber	Melanoma	BCC	Akiec	DF	Vasc
HAM10000	779	360	229	81	99
ISIC2019	4.522	3.323	867	239	253
Longitudinal	69	203	85	13	0
Total	5.370	3.886	1.181	333	352

Citra sintetis dihasilkan dengan rasio 1:1 terhadap citra asli setiap kelas minoritas dan digabungkan dengan HAM10000. Dataset dibagi menggunakan stratified split dengan rasio 70/15/15 (training/validasi/test). Citra sintetis hanya ditambahkan pada training set.

Table 2: Dataset untuk Training PanDerm ViT-Large

Sumber	Mel	BCC	Akiec	DF	Vasc	BKL	NV
HAM10000	779	360	229	81	99	1.099	6.705
Sintesis	779	360	229	81	99	0	0
Total	1.558	720	458	162	198	1.099	6.705

3.4 Pendekatan Pemodelan

3.4.1 Fine-Tuned Stable Diffusion

DermaDiff mengevaluasi empat konfigurasi difusi terhadap baseline untuk mengisolasi efek arsitektur dan metode adaptasi. Aturan desain kritis: hanya data pelatihan yang berubah antar eksperimen classifier, optimizer, hyperparameter, split, dan random seed tetap sama. Perlu dicatat

bahwa eksperimen DoRA hanya dilakukan pada arsitektur SDXL (Exp E), sedangkan SD 2.1 dan SD 3.5 Large tidak dievaluasi dengan DoRA. Hal ini disebabkan oleh keterbatasan sumber daya komputasi GPU: setiap konfigurasi difusi memerlukan pelatihan 5 adapter per-kelas secara terpisah ditambah satu kali pelatihan PanDerm, sehingga total komputasi untuk enam konfigurasi penuh (3 arsitektur $\times$ 2 metode) melebihi *compute unit* yang tersedia. SDXL dipilih sebagai arsitektur untuk eksperimen DoRA berdasarkan hasil awal yang menunjukkan keseimbangan terbaik antara kapasitas model dan efisiensi pelatihan.

Table 3: Konfigurasi Eksperimen

Exp	Arsitektur	Adapter	Peran
A	-	-	Baseline (tanpa augmentasi)
B	SD 2.1	LoRA	Baseline ringan
C	SDXL	LoRA	Scaled U-Net
D	SD 3.5 Large	LoRA	Transformer (MMDiT)
E	SDXL	DoRA	Adaptasi weight-decomposed

SD 2.1 menggunakan U-Net 865M parameter dengan DDPM noise prediction; SDXL berskala hingga 2,6B parameter dengan dual text encoder dan classifier-free guidance ($w=7,5$); SD 3.5 Large menggunakan MMDiT 8,1B parameter dengan rectified flow dan QK-normalization; DoRA (Exp E) mendekomposisi matriks bobot pretrained menjadi komponen magnitude dan direction.

Table 4: Konfigurasi Pelatihan LoRA/DoRA Per Eksperimen

Parameter	Exp B (SD 2.1)	Exp C (SDXL)	Exp D (SD 3.5)	Exp E (DoRA)
Adapter	LoRA	LoRA	LoRA	DoRA
Rank r	32	16	64	8
Alpha α	64	16	64	8
Learning rate	1e-4	1e-4	4e-4	5e-5
LR scheduler	cosine	constant	constant	cosine
Dropout	0,05	0,0	0,0	0,05
Resolusi	1024	1024	1024	1024
Presisi	fp16	fp16	bf16	fp16

3.4.2 PanDerm ViT-Large

PanDerm ViT-Large [8] digunakan sebagai classifier. Input 224×224 dipecah menjadi patch 16×16 menghasilkan 196 token berdimensi 1024. Encoder terdiri dari 24 blok transformer dengan 16-head MSA dan MLP ekspansi ke 4096 dimensi. Fine-tuning end-to-end menggunakan AdamW ($\text{lr } 5 \times 10^{-4}$, weight decay 0,05), 50 epochs, MixUp ($\alpha=0,8$), CutMix ($\alpha=1,0$), batch size 128.

3.4.3 MedGemma 4B-IT


MedGemma 4B IT [9] memanfaatkan attention rollout heatmap dan probabilitas klasifikasi dari PanDerm sebagai masukan untuk menghasilkan penjelasan tekstual mengenai dasar keputusan model yang lebih mudah dipahami oleh tenaga medis dibandingkan visualisasi heatmap saja.

3.5 Bagaimana Solusi Menjawab Masalah

DermaDiff mengatasi ketidakseimbangan data melalui augmentasi Stable Diffusion dan isu black-box via penjelasan tekstual MedGemma 4B IT. Prinsip escalate-never-clear diterapkan melalui prompt engineering agar MedGemma selalu menyoroti fitur mencurigakan tanpa pernah melabeli lesi sebagai “aman.” Pemilihan model akhir difokuskan pada sensitivitas kelas keganasan alih-alih akurasi agregat.

4 Arsitektur Produk dan Implementasi

4.1 Arsitektur Sistem



Gambar 2: Arsitektur sistem

Arsitektur sistem DermaDiff terdiri atas tiga lapisan yang saling terhubung. Frontend UI dibangun dengan Next.js dan Tailwind CSS, di-deploy melalui Vercel, menyediakan antarmuka bagi dokter untuk mengunggah citra dermoskopi. Permintaan dari frontend diteruskan ke Web Container berbasis FastAPI yang mengekspos tiga endpoint utama: GET /api/health untuk pemeriksaan status layanan, POST /api/classify untuk klasifikasi lesi, dan POST /api/explain_stream untuk streaming penjelasan klinis. Lapisan Backend berjalan di atas Modal sebagai platform serverless, dengan PanDerm ViT-Large pada NVIDIA T4 GPU untuk klasifikasi dan MedGemma pada NVIDIA A10G GPU untuk generasi penjelasan, memungkinkan setiap model diskalakan secara independen sesuai kebutuhan komputasinya.


4.2 Alur Perjalanan Pengguna

Alur pengguna utama: (1) Dokter mengunggah citra dermoskopi. (2) PanDerm menghasilkan distribusi probabilitas tujuh kelas dan attention rollout heatmap. (3) MedGemma menghasilkan penjelasan klinis dari konteks multimodal. (4) Dokter melihat hasil terintegrasi: prediksi, heatmap, dan penjelasan. (5) Dokter memutuskan langkah diagnostik selanjutnya dengan mempertimbangkan second opinion.

5 Hasil dan Diskusi

5.1 Performa Klasifikasi Keseluruhan


Augmentasi berbasis difusi secara konsisten meningkatkan performa classifier. Baseline (Exp A) mencatat skor terendah pada seluruh metrik agregat, sementara konfigurasi augmentasi menunjukkan tren peningkatan menuju SDXL DoRA.




Gambar 3: Metrik Klasifikasi Agregat pada HAM10000

Exp E (SDXL DoRA) dipilih sebagai konfigurasi akhir karena unggul pada Macro Recall (+4,1 pp dari baseline), Weighted Recall (+1,8 pp), dan Weighted F1 (+1,9 pp). Exp D mencatat Macro F1 marginal lebih tinggi (0,848 vs 0,847), namun selisih ini tidak bermakna secara praktis, sementara Exp E lebih unggul pada metrik recall yang menjadi prioritas klinis.

5.2 Recall dan F1 Per Kelas




Gambar 4: Recall Per Kelas Berdasarkan Eksperimen



Gambar 5: Skor F1 Per Kelas Berdasarkan Eksperimen

Augmentasi sintetis menghasilkan peningkatan terbesar pada kelas kritis secara klinis: recall melanoma naik dari 0,713 ke 0,820 pada Exp D (+10,7 pp), recall bcc dari 0,909 ke 0,935 pada Exp B dan 0,925 pada Exp E, dan recall akiec dari 0,735 ke 0,837 pada Exp C. Skor F1 turut meningkat bersamaan dengan recall (bcc F1: 0,859→0,923; mel F1: 0,688→0,712), menunjukkan model menjadi lebih sensitif tanpa mengorbankan presisi.


5.3 Analisis Kualitas Generatif



Gambar 6: Metrik Kualitas Generatif Agregat

SD 2.1 mencapai FID (Fréchet Inception Distance: metrik untuk mengukur kualitas dan kemiripan distribusi gambar sintetis terhadap gambar asli, di mana nilai semakin rendah berarti semakin baik) terendah namun keragaman terendah; SD 3.5 Large menghasilkan LPIPS (Learned Perceptual Image Patch Similarity: metrik untuk mengukur variasi dan perbedaan visual antar gambar yang dihasilkan, di mana nilai semakin tinggi berarti gambar semakin beragam) tertinggi namun FID dan MS-SSIM (Multi-Scale Structural Similarity Index Measure: metrik untuk menilai kualitas pelestarian struktur, kontras, dan detail gambar pada berbagai resolusi, di mana nilai semakin tinggi berarti integritas strukturalnya semakin baik) terburuk; SDXL DoRA menempati wilayah optimal dengan MS-SSIM tertinggi dan LPIPS mendekati terbaik. Konfigurasi yang menyeimbangkan FID, LPIPS, dan MS-SSIM secara konsisten mengungguli yang unggul hanya pada satu dimensi.

5.4 Evaluasi Cross-Domain pada PAD-UFES-20



Gambar 7: Metrik Agregat Cross-Domain pada PAD-UFES-20

Hanya konfigurasi berbasis SDXL (Exp C, E) yang mempertahankan atau meningkatkan performa dari baseline, dengan Exp E sebagai model terbaik dengan (akurasi: 0,530, +3,7 pp). Kedua konfigurasi SDXL mencatat skor MS-SSIM tertinggi, mendukung hipotesis bahwa MS-SSIM menangkap properti lesi yang invarian terhadap modalitas.

5.5 Evaluasi Interpretatif MedGemma

MedGemma 4B IT menghasilkan penjelasan berbahasa alami dengan memproses citra dermoskopi asli, attention rollout heatmap dari PanDerm, dan distribusi probabilitas tujuh kelas. Evaluasi kualitatif dilakukan pada empat dimensi: (1) konsistensi klinis, penjelasan selaras dengan prediksi dan probabilitas; (2) korespondensi heatmap, deskripsi akurat area yang disorot attention; (3) kepatuhan escalate-never-clear, sistem konsisten merekomendasikan evaluasi lanjut tanpa menyatakan lesi definitif jinak; serta (4) kesesuaian dengan ABCD rules (Asymmetry, Border, Color, Differential Structures), di mana MedGemma mengevaluasi karakteristik morfologi lesi secara terstruktur dan menghitung Total Dermoscopy Score (TDS) menggunakan formula $A \times 1.3 + B \times 0.1 + C \times 0.5 + D \times 0.5$, dengan interpretasi hasil berdasarkan threshold range yang ditetapkan sebagai kerangka penilaian risiko klinis tambahan.

5.6 Temuan Analitis Utama

DoRA vs. LoRA: Pada backbone SDXL identik, DoRA mencapai F1 lebih tinggi pada mayoritas kelas (bcc: 0,923 vs. 0,882; mel: 0,712 vs. 0,679) dan MS-SSIM agregat tertinggi (0,410 vs. 0,388) pada rank 8 vs. LoRA rank 16.

Arsitektur transformer di bawah kelangkaan data: MMDiT SD 3.5 Large menghasilkan FID tertinggi (235,0) dan MS-SSIM terendah (0,283) pada data fine-tuning terbatas, konsisten dengan kebutuhan data besar pada arsitektur transformer.

Kelas minoritas ekstrem: Recall dermatofibroma meningkat +20,0% pada Exp C dan Exp D meskipun profil generatif sangat berbeda, menunjukkan bahwa untuk kelas minoritas ekstrem, menyediakan sampel sintesis plausibel lebih penting daripada memilih generator optimal.

6 Analisis Pasar dan Model Bisnis

6.1 Lanskap Kompetitif

Beberapa produk deteksi kanker kulit berbasis AI telah tersedia secara komersial, namun masing-masing memiliki keterbatasan yang membedakannya dari DermaDiff. DermaSensor (AS) adalah perangkat handheld pertama dengan FDA clearance yang menggunakan analisis spektral, namun memerlukan hardware khusus dan tidak menyediakan penjelasan interpretatif. SkinVision (Belanda) adalah aplikasi smartphone bersertifikasi CE Class IIa dengan lebih dari 2 juta

pengguna, namun ditujukan untuk self-check pasien, bukan decision support dokter dari citra dermoskopi. DERM oleh Skin Analytics (Inggris) telah di-deploy di rumah sakit NHS dengan sensitivitas melanoma 95–100%, namun tidak menyertakan komponen interpretabilitas berbasis bahasa alami.

6.2 Diferensiasi DermaDiff

DermaDiff membedakan diri dari solusi yang ada melalui empat aspek :

1. DermaDiff mengintegrasikan augmentasi sintetis berbasis difusi, vision foundation model khusus dermatologi (PanDerm), dan interpretabilitas berbahasa alami (MedGemma) dalam satu pipeline end-to-end, kombinasi yang sejauh penelusuran kami masih jarang ditemukan.
2. Penjelasan tekstual klinis berbahasa alami atas hasil deteksi masih jarang ditemukan pada produk komersial; sebagian besar hanya menampilkan skor risiko atau heatmap tanpa konteks linguistik.
3. prinsip escalate-never-clear merupakan desain keselamatan yang belum diadopsi secara eksplisit oleh kompetitor; SkinVision misalnya mengklasifikasikan lesi ke kategori risiko rendah/sedang/tinggi, yang berpotensi memberikan rasa aman palsu pada kategori risiko rendah.
4. DermaDiff secara spesifik menargetkan dokter dengan akses alat dermoskop.

6.3 Target Pasar dan Konteks Indonesia

Indonesia memiliki rasio spesialis dermatologi terhadap populasi yang sangat rendah, dengan mayoritas terkonsentrasi di kota-kota besar di Pulau Jawa. Fasilitas kesehatan tingkat pertama (puskesmas dan klinik pratama) sering kali harus merujuk kasus lesi kulit ke rumah sakit tipe B atau A, menyebabkan keterlambatan diagnosis yang dapat berdampak fatal pada kasus melanoma. DermaDiff menargetkan dokter yang memiliki akses dermoskop namun belum menguasai interpretasi pola dermoskopi secara mendalam, suatu kondisi yang lazim di luar pusat rujukan. Dengan menyediakan second opinion instan disertai penjelasan klinis, DermaDiff dapat mengurangi waktu tunggu rujukan dan meningkatkan ketepatan triase.

6.4 Model Bisnis

Model bisnis yang direncanakan adalah kerjasama institusional (B2B) dengan rumah sakit dan jaringan klinik, bukan model konsumen langsung. Pendekatan ini dipilih karena tiga alasan: (1) produk memerlukan input dermoskopi yang hanya tersedia di fasilitas tertentu, (2) keputusan klinis membutuhkan konteks profesional yang tidak sesuai untuk self-service, dan (3) institusi kesehatan memiliki jalur pengadaan yang lebih prediktabel. Pilot awal direncanakan melalui kerjasama penelitian dengan rumah sakit pendidikan untuk mengumpulkan data validasi klinis sebelum komersialisasi penuh.

Model pendapatan berbasis subscription per-fasilitas dengan tiga tingkatan paket. Paket Starter (20 inferensi/hari, Rp 600.000/bulan) untuk klinik pratama dengan satu dokter spesialis. Paket Profesional (50 inferensi/hari, Rp 1.400.000/bulan) untuk rumah sakit tipe C. Paket Enterprise (100 inferensi/hari, Rp 2.500.000/bulan) untuk rumah sakit tipe A/B sebagai pusat rujukan. Seluruh paket mencakup fitur yang sama, yaitu klasifikasi tujuh kelas lesi kulit, attention rollout heatmap, dan penjelasan klinis berbasis ABCD rules; perbedaan antar paket terletak pada kuota inferensi dan tingkat dukungan teknis.amortisasi biaya infrastruktur lintas fasilitas sekaligus menyesuaikan harga subscription dengan kapasitas dan kebutuhan masing-masing segmen pengguna.

6.5 Analisis Biaya

Biaya development DermaDiff bersifat minimal, dengan total sunk cost sekitar Rp 1,97 juta yang seluruhnya berasal dari langganan Google Colab Pro+ untuk proses fine-tuning empat konfigurasi difusi dan lima eksperimen PanDerm ViT-Large. Tenaga kerja tim tidak dibebankan biaya karena

bersifat kontribusi in-kind dalam konteks proyek akademik. Biaya operasional bulanan didominasi oleh GPU keep-warm untuk menjaga PanDerm (NVIDIA T4) dan MedGemma (NVIDIA A10G) tetap responsif, dengan baseline Rp 3,3 juta per bulan yang berskala mengikuti pertumbuhan jumlah fasilitas. Komponen lain mencakup infrastruktur dan domain, sumber daya manusia developer part-time mulai tahun kedua, biaya akuisisi klien, serta konsultasi awal regulasi BPOM sebesar Rp 25 juta pada tahun ketiga.

Proyeksi laba rugi lima tahun disusun berdasarkan skenario pertumbuhan fasilitas mitra dari 3 menjadi 20, dengan harga subscription blended (rata-rata tertimbang dari tiga paket) sekitar Rp 1,17 juta per faskes per bulan. Dari basis ini, revenue tahunan meningkat dari Rp 69,9 juta pada tahun pertama menjadi Rp 279,6 juta pada tahun kelima, sejalan dengan pertumbuhan jumlah faskes. Di sisi biaya, komponen GPU keep-warm dan infrastruktur bersifat relatif tetap sehingga tidak bertumbuh proporsional dengan jumlah faskes, sementara biaya SDM dan regulasi hanya muncul pada tahun-tahun tertentu. Akibatnya, net margin meningkat dari 16,6% pada tahun pertama menjadi 50,1% pada tahun kelima, karena revenue yang terus tumbuh menyerap biaya tetap yang relatif stagnan. Dengan laba tahunan yang terakumulasi setiap tahun sejak tahun pertama, laba kumulatif mencapai Rp 276,6 juta pada akhir tahun kelima, atau setara ROI 140,5% terhadap biaya development awal sebesar Rp 1,97 juta. Rincian lengkap perhitungan biaya, struktur paket, dan proyeksi finansial tersedia pada Lampiran 2.

7 Kelayakan dan Strategi Implementasi

7.1 Jalur Adopsi

DermaDiff menargetkan strategi adopsi bertahap. Pada fase awal, sistem beroperasi sebagai aplikasi web standalone yang dapat diakses melalui browser tanpa instalasi tambahan. Pada fase lanjutan, sistem dapat diintegrasikan ke Picture Archiving and Communication Systems (PACS) melalui antarmuka standar DICOM/HL7 FHIR. Target adopter mencakup dokter dengan akses dermoskop, penyedia layanan teledermatologi, serta fasilitas kesehatan di daerah terpencil dengan keterbatasan akses spesialis dermatologi.

7.2 Kelayakan Implementasi

PanDerm ViT-Large (~1,2 GB) berjalan pada NVIDIA T4 GPU; MedGemma 4B IT (~8 GB) berjalan pada NVIDIA A10G GPU. Pada kondisi warm start, total pipeline inferensi mencapai ~15 detik per citra (klasifikasi ~3 detik, penjelasan ~12 detik). Cold start membutuhkan tambahan ~20–30 detik, dapat dimitigasi melalui Modal memory snapshots dan keep-warm configuration. Dependensi eksternal utama adalah bobot model (Hugging Face) dan pustaka ML standar (PyTorch, Transformers, diffusers); infrastruktur cloud regional (AWS/Google Cloud Jakarta) dapat meminimalkan latensi jaringan di Indonesia.

7.3 Potensi Skalabilitas

DermaDiff dirancang untuk skalabilitas pada tiga sumbu: ekspansi geografis melalui replikasi backend inferensi dari regional endpoint, perluasan cakupan diagnostik melalui taksonomi kelas yang lebih luas seperti ISIC 2019, dan ekspansi modalitas ke fotografi smartphone klinis setelah performa cross-domain memadai untuk triase yang aman.

8 Pertimbangan Regulasi AI

Sebagai perangkat lunak medis berbasis AI, DermaDiff perlu mempertimbangkan jalur regulasi yang sesuai. Di Indonesia, perangkat lunak sebagai alat kesehatan (SaMD) diatur oleh Kementerian Kesehatan dan BPOM. Langkah awal yang direncanakan adalah deployment sebagai alat penelitian dan pendidikan di rumah sakit pendidikan, yang tidak memerlukan sertifikasi penuh, sambil mengumpulkan bukti klinis yang diperlukan untuk pengajuan izin edar di masa depan. Referensi regulasi internasional mencakup CE marking (Eropa) dan FDA clearance (AS), yang telah diperoleh oleh kompetitor seperti SkinVision dan DermaSensor.

9 Kesimpulan

DermaDiff mengintegrasikan augmentasi sintetis berbasis difusi, vision foundation model khusus dermatologi, dan interpretabilitas berbahasa alami dalam satu pipeline end-to-end sebagai clinical decision support untuk deteksi kanker kulit. Augmentasi berbasis Stable Diffusion terbukti meningkatkan recall pada kelas kritis, dengan peningkatan terbesar pada melanoma (+10,7 pp) dan AKIEC (+10,2 pp). Konfigurasi terbaik dicapai oleh SDXL dengan adapter DoRA, menghasilkan Macro F1 0,847 dan Weighted F1 0,897.

Setiap prediksi dilengkapi attention rollout heatmap dan penjelasan klinis berbahasa alami dari MedGemma berbasis ABCD rules, kerangka analisis yang luas digunakan dokter dalam praktik dermoskopi, sehingga keputusan model dapat diaudit oleh tenaga medis. DermaDiff membedakan diri dari solusi komersial melalui integrasi unik tiga komponen (difusi, PanDerm, MedGemma) serta prinsip keselamatan escalate-never-clear yang belum diadopsi kompetitor. Biaya operasional Rp 127 per inferensi memungkinkan model subscription tiga tingkat (Starter, Profesional, Enterprise) yang layak secara ekonomis untuk fasilitas kesehatan Indonesia dari klinik pratama hingga rumah sakit rujukan.

Pekerjaan di masa depan mencakup validasi klinis formal dengan dermatologis Indonesia, pengumpulan dataset dermoskopi lokal untuk mengatasi bias skin tone, ekspansi modalitas ke fotografi smartphone klinis, dan eksplorasi jalur regulasi BPOM.

Lampiran

1. Web Produk, Dokumentasi Penelitian, dan Formulir Umpan Balik: <https://dermadiff-web.vercel.app>
2. Analisis Finansial DermaDiff: <https://its.id/m/dermadiff/financialanalysis>

Referensi

- [1] H. Kittler et al., “Diagnostic Accuracy of Dermoscopy,” *Lancet Oncology*, vol. 3, no. 3, 2002.
- [2] WHO, “Ultraviolet Radiation and the INTERSUN Programme,” 2024.
- [3] American Cancer Society, “Key Statistics for Melanoma Skin Cancer,” 2024.
- [4] American Cancer Society, “Survival Rates for Melanoma Skin Cancer by Stage,” 2024.
- [5] A. Esteva et al., “Dermatologist-Level Classification of Skin Cancer with DNNs,” *Nature*, vol. 542, 2017.
- [6] P. Tschandl et al., “The HAM10000 Dataset,” *Scientific Data*, vol. 5, 2018.
- [7] M. Buda et al., “Class Imbalance Problem in CNNs,” *Neural Networks*, vol. 106, 2018.
- [8] S. Yan et al., “A Multimodal Vision Foundation Model for Clinical Dermatology,” *Nature Medicine*, 2025.
- [9] A. Sellergren et al., “MedGemma Technical Report,” arXiv:2507.05201, 2025.
- [10] F. Perez et al., “Data Augmentation for Skin Lesion Analysis,” *ISIC Workshop, MICCAI*, 2018.
- [11] B. Ozdemir and I. Pacal, “A robust deep learning framework for multiclass skin cancer classification,” *Scientific Reports*, vol. 15, Art. no. 4938, 2025.
- [12] M. Frid-Adar et al., “GAN-Based Synthetic Medical Image Augmentation,” *Neurocomputing*, vol. 321, 2018.
- [13] A. Creswell et al., “Generative Adversarial Networks: An Overview,” *IEEE SPM*, vol. 35, 2018.

- [14] A. Bissoto et al., “Skin Lesion Synthesis With GANs,” CMIG, vol. 86, 2021.
- [15] R. Rombach et al., “High-Resolution Image Synthesis With LDMs,” CVPR, 2022.
- [16] E. J. Hu et al., “LoRA: Low-Rank Adaptation of LLMs,” ICLR, 2022.
- [17] R. R. Selvaraju et al., “Grad-CAM,” ICCV, 2017.
- [18] A. Lucieri et al., “ExAID: Multimodal Explanation for CAD of Skin Lesions,” CMPB, vol. 194, 2020.
- [19] M. Giavina-Bianchi, W. G. Vitor, V. F. de Paiva, A. L. Okita, R. M. Sousa, and B. Machado, “Explainability agreement between dermatologists and five visual explanations techniques in deep neural networks for melanoma AI classification,” *Frontiers in Medicine*, vol. 10, 2023.
- [20] N. Codella et al., “ISIC 2019 Challenge Dataset,” ISIC Archive, 2019.
- [21] S.-Y. Liu et al., “DoRA: Weight-Decomposed Low-Rank Adaptation,” ICML, 2024.
- [22] J. Ho dan T. Salimans, “Classifier-Free Diffusion Guidance,” arXiv:2207.12598, 2022.